Data Engineering Programming

Trabalho Final - FIAP MBA - Prof. Marcelo Barbosa Pinto

Relatório de pedidos de 2025 com pagamento recusado (status=false) e fraude=false, em PySpark, orientado a objetos e com injeção de dependências.

Integrante	RM
Priscila Cristina Mendes Cardoso	373153
Andre Victor Bagatin	374773
Felipe Nogueira da Silva	373111
Heloisa Cordeiro Silva	373370
Leonardo Machado de Andrade	373150
Nicolas Galhardo Lhen	374205

Repositório público no GitHub:

`https://github.com/AndreBagatin/fiap-dep-pyspark-relatorio-pedidos`

Arquitetura e injeção de dependências

main.py é o Aggregation Root: a classe Application instancia Settings, SparkSessionManager, DataReader, RelatorioPedidos, ParquetWriter e Pipeline, injetando-os via construtor. Nenhuma outra classe cria suas dependências.

Pacotes: **config** (Settings), **session** (SparkSessionManager), **io_utils** (schemas, DataReader, ParquetWriter), **business** (RelatorioPedidos) e **pipeline** (Pipeline: leitura, negócio e escrita).

Todos os DataFrames usam StructType explícito (inclusive o struct aninhado avaliacao_fraude); não há inferência de schema nem notebooks.

Decisões de negócio

Valor total do pedido = valor_unitario x quantidade (pedidos). O valor_pagamento difere em 21.297 dos 60.096 pedidos (ex.: desconto no PIX), portanto não representa o valor do pedido.

Join 1:1: 60.096 pedidos e 60.096 pagamentos, ambos com id_pedido único; inner join por id_pedido, sem duplicidade.

Filtros: ano de data_criacao = 2025; status = false e avaliacao_fraude.fraude = false. Resultado real: 1.473 pedidos.

Ordenação: uf, forma_pagamento e data do pedido; gravação em parquet (1 partição para preservar a ordem).

Logging e tratamento de erros

RelatorioPedidos importa logging, configura logging.basicConfig(level=INFO) e registra a contagem de cada etapa. Falhas caem em try/except, são registradas com logging.error e relançadas como RelatorioPedidosError.

Como executar (detalhes no README.md do repositório)

pip install -r requirements.txt; pip install .; python scripts/download_datasets.py; python main.py; pytest

Repositório: https://github.com/AndreBagatin/fiap-dep-pyspark-relatorio-pedidos

Aggregation Root: instancia e injeta todas as dependências

main.py - linhas 1 a 19

```python
"""Aggregation Root: único lugar que instancia as dependências e as injeta."""

import logging
import sys

from relatorio_pedidos.business.relatorio_pedidos import RelatorioPedidos
from relatorio_pedidos.config.settings import Settings
from relatorio_pedidos.io_utils.readers import DataReader
from relatorio_pedidos.io_utils.schemas import PagamentosSchema, PedidosSchema
from relatorio_pedidos.io_utils.writers import ParquetWriter
from relatorio_pedidos.pipeline.pipeline import Pipeline
from relatorio_pedidos.session.spark_session_manager import SparkSessionManager


class Application:
    """Monta o grafo de dependências e executa o pipeline."""

    def __init__(self, config_path: str | None = None):
        self._config_path = config_path
```

main.py - linhas 21 a 37

```python
    def run(self) -> int:
        settings = Settings.load(self._config_path)
        session_manager = SparkSessionManager(settings)
        try:
            spark = session_manager.get_session()
            pipeline = Pipeline(
                reader=DataReader(spark, settings, PedidosSchema.get(), PagamentosSchema.get()),
                relatorio=RelatorioPedidos(settings.ano_relatorio, settings.log_contagens),
                writer=ParquetWriter(settings),
            )
            pipeline.run()
            return 0
        except Exception:  # apenas converte a falha em código de saída; o detalhe já foi logado
            logging.getLogger(type(self).__name__).exception("Execução interrompida por erro")
            return 1
        finally:
            session_manager.stop()
```

main.py - linhas 39 a 47

```python
    @classmethod
    def cli(cls, argv: list[str] | None = None) -> None:
        """Ponto de entrada de linha de comando: [caminho_do_yaml] opcional."""
        args = sys.argv[1:] if argv is None else argv
        sys.exit(cls(config_path=args[0] if args else None).run())


if __name__ == "__main__":
    Application.cli()
```

Configurações externas (caminhos, opções de leitura, ano)

config/settings.yaml - linhas 1 a 13

```yaml
# Configurações do pipeline (ver src/relatorio_pedidos/config/settings.py).
# Variáveis de ambiente PEDIDOS_PATH, PAGAMENTOS_PATH, OUTPUT_PATH e ANO_RELATORIO
# têm precedência sobre este arquivo.
spark:
  app_name: relatorio-pedidos-recusados-legitimos
  master: "local[*]"
  shuffle_partitions: 8
  timezone: America/Sao_Paulo  # fuso usado para interpretar/exibir timestamps (saída independe da máquina)

paths:
  pedidos: data/input/datasets-csv-pedidos/data/pedidos/
  pagamentos: data/input/dataset-json-pagamentos/data/pagamentos/
  output: data/output/relatorio_pedidos
```

config/settings.yaml - linhas 15 a 30

```yaml
file_options:
  mode: FAILFAST
  pedidos_csv:
    sep: ";"
    header: true
    compression: gzip
  pagamentos_json:
    compression: gzip

output:
  mode: overwrite
  partitions: 1

negocio:
  ano_relatorio: 2025
  log_contagens: true  # false evita um job Spark extra (count) por etapa
```

Pacote config: classe Settings

src/relatorio_pedidos/config/settings.py - linhas 1 a 19

```python
"""Configurações centralizadas do projeto.

Ordem de precedência (da menor para a maior):
1. valores padrão definidos na classe ``Settings``;
2. arquivo YAML (``config/settings.yaml`` ou o indicado em ``RELATORIO_CONFIG``);
3. variáveis de ambiente (``PEDIDOS_PATH``, ``PAGAMENTOS_PATH``, ``OUTPUT_PATH``,
   ``ANO_RELATORIO``).
"""

import os
from dataclasses import dataclass, replace
from pathlib import Path

import yaml


@dataclass(frozen=True)
class Settings:
    """Parâmetros de execução do pipeline."""
```

src/relatorio_pedidos/config/settings.py - linhas 21 a 36

```
    # Spark
    app_name: str = "relatorio-pedidos-recusados-legitimos"
    master: str = "local[*]"
    shuffle_partitions: int = 8
    timezone: str = "America/Sao_Paulo"

    # Entrada
    pedidos_path: str = "data/input/datasets-csv-pedidos/data/pedidos/"
    pagamentos_path: str = "data/input/dataset-json-pagamentos/data/pagamentos/"

    # Opções de leitura
    pedidos_sep: str = ";"
    pedidos_header: bool = True
    pedidos_compression: str = "gzip"
    pagamentos_compression: str = "gzip"
    read_mode: str = "FAILFAST"
```

src/relatorio_pedidos/config/settings.py - linhas 38 a 48

```
    # Saída
    output_path: str = "data/output/relatorio_pedidos"
    output_mode: str = "overwrite"
    output_partitions: int = 1

    # Regras de negócio
    ano_relatorio: int = 2025
    log_contagens: bool = True

    ENV_CONFIG = "RELATORIO_CONFIG"
    DEFAULT_CONFIG_FILE = "config/settings.yaml"
```

src/relatorio_pedidos/config/settings.py - linhas 50 a 58

```python
    @classmethod
    def load(cls, path: str | None = None) -> "Settings":
        """Carrega as configurações combinando padrões, YAML e variáveis de ambiente."""
        settings = cls()
        yaml_path = Path(path or os.environ.get(cls.ENV_CONFIG) or cls.DEFAULT_CONFIG_FILE)
        if yaml_path.is_file():
            with open(yaml_path, "r", encoding="utf-8") as file:
                settings = cls._from_dict(settings, yaml.safe_load(file) or {})
        return cls._from_env(settings)
```

src/relatorio_pedidos/config/settings.py - linhas 60 a 79

```python
    @staticmethod
    def _from_dict(base: "Settings", raw: dict) -> "Settings":
        spark = raw.get("spark", {})
        paths = raw.get("paths", {})
        pedidos_csv = raw.get("file_options", {}).get("pedidos_csv", {})
        pagamentos_json = raw.get("file_options", {}).get("pagamentos_json", {})
        output = raw.get("output", {})
        negocio = raw.get("negocio", {})
        valores = {
            "app_name": spark.get("app_name"),
            "master": spark.get("master"),
            "shuffle_partitions": spark.get("shuffle_partitions"),
            "timezone": spark.get("timezone"),
            "pedidos_path": paths.get("pedidos"),
            "pagamentos_path": paths.get("pagamentos"),
            "pedidos_sep": pedidos_csv.get("sep"),
            "pedidos_header": pedidos_csv.get("header"),
            "pedidos_compression": pedidos_csv.get("compression"),
            "pagamentos_compression": pagamentos_json.get("compression"),
            "read_mode": raw.get("file_options", {}).get("mode"),
```

src/relatorio_pedidos/config/settings.py - linhas 80 a 97

```
            "output_path": paths.get("output"),
            "output_mode": output.get("mode"),
            "output_partitions": output.get("partitions"),
            "ano_relatorio": negocio.get("ano_relatorio"),
            "log_contagens": negocio.get("log_contagens"),
        }
        return replace(base, **{k: v for k, v in valores.items() if v is not None})

    @staticmethod
    def _from_env(base: "Settings") -> "Settings":
        env = os.environ
        valores = {
            "pedidos_path": env.get("PEDIDOS_PATH"),
            "pagamentos_path": env.get("PAGAMENTOS_PATH"),
            "output_path": env.get("OUTPUT_PATH"),
            "ano_relatorio": int(env["ANO_RELATORIO"]) if env.get("ANO_RELATORIO") else None,
        }
        return replace(base, **{k: v for k, v in valores.items() if v is not None})
```

Pacote session: SparkSessionManager

src/relatorio_pedidos/session/spark_session_manager.py - linhas 1 a 11

```
from pyspark.sql import SparkSession

from relatorio_pedidos.config.settings import Settings


class SparkSessionManager:
    """Gerencia o ciclo de vida (criar, obter e encerrar) da SparkSession."""

    def __init__(self, settings: Settings):
        self._settings = settings
        self._spark: SparkSession | None = None
```

src/relatorio_pedidos/session/spark_session_manager.py - linhas 13 a 31

```
    def get_session(self) -> SparkSession:
        """Cria a sessão na primeira chamada e a reutiliza nas seguintes."""
        if self._spark is None:
            self._spark = (
                SparkSession.builder.appName(self._settings.app_name)
                .master(self._settings.master)
                .config("spark.sql.shuffle.partitions", self._settings.shuffle_partitions)
                .config("spark.sql.session.timeZone", self._settings.timezone)
                .config("spark.ui.showConsoleProgress", "false")
                .getOrCreate()
            )
            self._spark.sparkContext.setLogLevel("WARN")
        return self._spark

    def stop(self) -> None:
        """Encerra a sessão, se estiver ativa."""
        if self._spark is not None:
            self._spark.stop()
            self._spark = None
```

Schemas explícitos (StructType), inclusive aninhado

src/relatorio_pedidos/io_utils/schemas.py - linhas 1 a 13

```
from pyspark.sql.types import (
    BooleanType,
    DoubleType,
    LongType,
    StringType,
    StructField,
    StructType,
    TimestampType,
)


class PedidosSchema:
    """Schema explícito do dataset de pedidos (CSV)."""
```

src/relatorio_pedidos/io_utils/schemas.py - linhas 15 a 31

```
15      @staticmethod
16      def get() -> StructType:
17          return StructType(
18              [
19                  StructField("id_pedido", StringType(), True),
20                  StructField("produto", StringType(), True),
21                  StructField("valor_unitario", DoubleType(), True),
22                  StructField("quantidade", LongType(), True),
23                  StructField("data_criacao", TimestampType(), True),
24                  StructField("uf", StringType(), True),
25                  StructField("id_cliente", LongType(), True),
26              ]
27          )
28
29
30  class PagamentosSchema:
31      """Schema explícito do dataset de pagamentos (JSON), incluindo o objeto aninhado."""
```

src/relatorio_pedidos/io_utils/schemas.py - linhas 33 a 40

```
33      @staticmethod
34      def avaliacao_fraude() -> StructType:
35          return StructType(
36              [
37                  StructField("fraude", BooleanType(), True),
38                  StructField("score", DoubleType(), True),
39              ]
40          )
```

src/relatorio_pedidos/io_utils/schemas.py - linhas 42 a 53

```
    @staticmethod
    def get() -> StructType:
        return StructType(
            [
                StructField("id_pedido", StringType(), True),
                StructField("forma_pagamento", StringType(), True),
                StructField("valor_pagamento", DoubleType(), True),
                StructField("status", BooleanType(), True),
                StructField("data_processamento", TimestampType(), True),
                StructField("avaliacao_fraude", PagamentosSchema.avaliacao_fraude(), True),
            ]
        )
```

Pacote io_utils: leitura de CSV e JSON com schema

src/relatorio_pedidos/io_utils/readers.py - linhas 1 a 8

```
from pyspark.sql import DataFrame, SparkSession
from pyspark.sql.types import StructType

from relatorio_pedidos.config.settings import Settings


class DataReader:
    """Lê os datasets de entrada sempre com schema explícito (sem inferência)."""
```

src/relatorio_pedidos/io_utils/readers.py - linhas 10 a 20

```
    def __init__(
        self,
        spark: SparkSession,
        settings: Settings,
        pedidos_schema: StructType,
        pagamentos_schema: StructType,
    ):
        self._spark = spark
        self._settings = settings
        self._pedidos_schema = pedidos_schema
        self._pagamentos_schema = pagamentos_schema
```

src/relatorio_pedidos/io_utils/readers.py - linhas 22 a 33

```
22      def read_pedidos(self) -> DataFrame:
23          """Lê os pedidos (CSV com separador e cabeçalho definidos na configuração)."""
24          return (
25              self._spark.read.schema(self._pedidos_schema)
26              .option("compression", self._settings.pedidos_compression)
27              .option("mode", self._settings.read_mode)
28              .csv(
29                  self._settings.pedidos_path,
30                  header=self._settings.pedidos_header,
31                  sep=self._settings.pedidos_sep,
32              )
33          )
```

src/relatorio_pedidos/io_utils/readers.py - linhas 35 a 42

```
35      def read_pagamentos(self) -> DataFrame:
36          """Lê os pagamentos (JSON, um objeto por linha, com avaliacao_fraude aninhada)."""
37          return (
38              self._spark.read.schema(self._pagamentos_schema)
39              .option("compression", self._settings.pagamentos_compression)
40              .option("mode", self._settings.read_mode)
41              .json(self._settings.pagamentos_path)
42          )
```

Pacote io_utils: escrita em parquet

src/relatorio_pedidos/io_utils/writers.py - linhas 1 a 13

```python
from pyspark.sql import DataFrame

from relatorio_pedidos.config.settings import Settings


class ParquetWriter:
    """Grava o relatório em formato parquet."""

    def __init__(self, settings: Settings):
        self._settings = settings

    def write(self, df: DataFrame) -> str:
        """Grava o DataFrame e devolve o caminho de saída.
```

src/relatorio_pedidos/io_utils/writers.py - linhas 15 a 23

```python
        O ``coalesce`` é aplicado depois da ordenação e não a desfaz: ele apenas
        junta partições vizinhas, preservando a ordem global do relatório.
        """
        (
            df.coalesce(self._settings.output_partitions)
            .write.mode(self._settings.output_mode)
            .parquet(self._settings.output_path)
        )
        return self._settings.output_path
```

Pacote business: regras, logging e try/except

src/relatorio_pedidos/business/relatorio_pedidos.py - linhas 1 a 19

```python
import logging
from typing import Callable

from pyspark.sql import DataFrame
from pyspark.sql import functions as F

logger = logging.getLogger(__name__)


class RelatorioPedidosError(Exception):
    """Erro controlado lançado quando uma etapa da lógica de negócio falha."""


class RelatorioPedidos:
    """Regras de negócio do relatório de pedidos com pagamento recusado e fraude=false.

    Etapas: filtro do ano -> valor total -> filtro de pagamentos -> join ->
    seleção de colunas -> ordenação.
    """
```

src/relatorio_pedidos/business/relatorio_pedidos.py - linhas 21 a 36

```python
    COLUNAS_RELATORIO = ["id_pedido", "uf", "forma_pagamento", "valor_total", "data_pedido"]

    def __init__(self, ano: int, log_contagens: bool = True):
        logging.basicConfig(level=logging.INFO, format="%(asctime)s - %(levelname)s - %(message)s")
        self._ano = ano
        self._log_contagens = log_contagens

    def filtrar_pagamentos_recusados_legitimos(self, pagamentos: DataFrame) -> DataFrame:
        """Mantém pagamentos recusados (status=false) avaliados como legítimos (fraude=false)."""
        return pagamentos.filter(
            (F.col("status") == F.lit(False)) & (F.col("avaliacao_fraude.fraude") == F.lit(False))
        )

    def filtrar_ano(self, pedidos: DataFrame) -> DataFrame:
        """Mantém apenas pedidos criados no ano do relatório."""
        return pedidos.filter(F.year(F.col("data_criacao")) == self._ano)
```

src/relatorio_pedidos/business/relatorio_pedidos.py - linhas 38 a 54

```
38      def calcular_valor_total(self, pedidos: DataFrame) -> DataFrame:
39          """Valor total do pedido = valor_unitario * quantidade."""
40          return pedidos.withColumn("valor_total", F.col("valor_unitario") * F.col("quantidade"))
41
42      def juntar(self, pedidos: DataFrame, pagamentos: DataFrame) -> DataFrame:
43          """Junção interna pedido x pagamento por id_pedido (relação 1:1 nos datasets)."""
44          return pedidos.join(pagamentos, on="id_pedido", how="inner")
45
46      def selecionar_colunas(self, df: DataFrame) -> DataFrame:
47          """Seleciona as 5 colunas do relatório."""
48          return df.select(
49              "id_pedido",
50              "uf",
51              "forma_pagamento",
52              "valor_total",
53              F.col("data_criacao").alias("data_pedido"),
54          )
```

src/relatorio_pedidos/business/relatorio_pedidos.py - linhas 56 a 74

```
56      def ordenar(self, df: DataFrame) -> DataFrame:
57          """Ordena por UF, forma de pagamento e data do pedido (id_pedido desempata)."""
58          return df.orderBy("uf", "forma_pagamento", "data_pedido", "id_pedido")
59
60      def gerar_relatorio(self, pedidos: DataFrame, pagamentos: DataFrame) -> DataFrame:
61          """Executa todas as etapas e devolve o DataFrame final do relatório."""
62          logger.info("Iniciando a geração do relatório (ano %s)", self._ano)
63          pedidos = self._executar("Filtro do ano", self.filtrar_ano, pedidos)
64          pedidos = self._executar("Cálculo do valor total", self.calcular_valor_total, pedidos)
65          pagamentos = self._executar(
66              "Filtro de pagamentos recusados e legítimos",
67              self.filtrar_pagamentos_recusados_legitimos,
68              pagamentos,
69          )
70          df = self._executar("Join pedidos x pagamentos", self.juntar, pedidos, pagamentos)
71          df = self._executar("Seleção de colunas", self.selecionar_colunas, df)
72          df = self._executar("Ordenação", self.ordenar, df)
73          logger.info("Relatório gerado com sucesso")
74          return df
```

src/relatorio_pedidos/business/relatorio_pedidos.py - linhas 76 a 87

```python
    def _executar(self, etapa: str, funcao: Callable[..., DataFrame], *args: DataFrame) -> DataFrame:
        """Roda uma etapa registrando a contagem de registros; falhas viram RelatorioPedidosError."""
        try:
            resultado = funcao(*args)
            if self._log_contagens:
                logger.info("Etapa '%s' concluída: %d registros", etapa, resultado.count())
            else:
                logger.info("Etapa '%s' concluída", etapa)
            return resultado
        except Exception as erro:
            logger.error("Falha na etapa '%s': %s", etapa, erro)
            raise RelatorioPedidosError(f"Falha na etapa '{etapa}'") from erro
```

Pacote pipeline: contratos (Protocol) injetados no Pipeline

src/relatorio_pedidos/pipeline/contracts.py - linhas 1 a 17

```python
from typing import Protocol

from pyspark.sql import DataFrame


class DataSource(Protocol):
    """Contrato de quem fornece os DataFrames de entrada (ex.: DataReader)."""

    def read_pedidos(self) -> DataFrame: ...

    def read_pagamentos(self) -> DataFrame: ...


class ReportBuilder(Protocol):
    """Contrato da lógica de negócio que produz o relatório (ex.: RelatorioPedidos)."""

    def gerar_relatorio(self, pedidos: DataFrame, pagamentos: DataFrame) -> DataFrame: ...
```

src/relatorio_pedidos/pipeline/contracts.py - linhas 20 a 23

```python
class DataSink(Protocol):
    """Contrato de quem grava o resultado (ex.: ParquetWriter)."""

    def write(self, df: DataFrame) -> str: ...
```

Pacote pipeline: orquestração

src/relatorio_pedidos/pipeline/pipeline.py - linhas 1 a 18

```python
import logging

from relatorio_pedidos.pipeline.contracts import DataSink, DataSource, ReportBuilder


class Pipeline:
    """Orquestra leitura -> transformação -> escrita.

    Depende apenas de contratos (Protocol) e não cria suas dependências:
    todas chegam prontas pelo construtor, montadas no Aggregation Root (main.py).
    """

    _logger = logging.getLogger("relatorio_pedidos.pipeline")

    def __init__(self, reader: DataSource, relatorio: ReportBuilder, writer: DataSink):
        self._reader = reader
        self._relatorio = relatorio
        self._writer = writer
```

src/relatorio_pedidos/pipeline/pipeline.py - linhas 20 a 28

```python
    def run(self) -> str:
        """Executa o pipeline completo e devolve o caminho do parquet gerado."""
        self._logger.info("Pipeline iniciado")
        pedidos = self._reader.read_pedidos()
        pagamentos = self._reader.read_pagamentos()
        df = self._relatorio.gerar_relatorio(pedidos, pagamentos)
        caminho = self._writer.write(df)
        self._logger.info("Pipeline concluído. Parquet gravado em: %s", caminho)
        return caminho
```

Empacotamento: pyproject.toml

pyproject.toml - linhas 1 a 20

```toml
[build-system]
requires = ["setuptools>=68.0"]
build-backend = "setuptools.build_meta"

[project]
name = "fiap-dep-pyspark-relatorio-pedidos"
version = "1.0.0"
description = "Relatório de pedidos com pagamento recusado e fraude=false (PySpark, POO e injeção de dependências)."
readme = "README.md"
requires-python = ">=3.10"
license = { text = "MIT" }
authors = [
  { name = "Grupo FIAP - Data Engineering Programming" },
]
classifiers = [
    "Programming Language :: Python :: 3",
    "Operating System :: OS Independent",
]
dependencies = [
    "pyspark>=4.0.0,<5.0.0",
```

pyproject.toml - linhas 21 a 35

```toml
    "pyyaml>=6.0",
]

[project.optional-dependencies]
dev = [
    "pytest>=8.0",
    "ruff>=0.5",
    "build>=1.0",
    "pygments>=2.17",
    "pillow>=10.0",
    "reportlab>=4.0",
]

[tool.setuptools.packages.find]
where = ["src"]
```

pyproject.toml - linhas 37 a 50

```toml
[tool.pytest.ini_options]
pythonpath = ["src", "."]
testpaths = ["tests"]
addopts = "-v"

[tool.ruff]
line-length = 110
src = ["src", "tests", "."]

[tool.ruff.lint]
select = ["E", "F", "W", "I"]

[tool.ruff.lint.isort]
known-first-party = ["main", "relatorio_pedidos"]
```

Empacotamento: requirements.txt

requirements.txt - linhas 1 a 3

```
pyspark==4.2.0
PyYAML==6.0.3
pytest==9.1.1
```

Empacotamento: requirements-dev.txt

requirements-dev.txt - linhas 1 a 7

```
-r requirements.txt
ruff==0.17.0
build==1.6.1
# Usados apenas por scripts/gerar_evidencias.py (PDF de entrega)
Pygments==2.21.0
pillow==12.3.0
reportlab==5.0.1
```

Empacotamento: MANIFEST.in

MANIFEST.in - linhas 1 a 11

```
include README.md
include LICENSE
include .gitignore
include requirements.txt
include requirements-dev.txt
include main.py
include config/settings.yaml
recursive-include scripts *.py
recursive-include tests *.py
recursive-include src *.py
global-exclude __pycache__ *.py[cod]
```

Testes: fixtures com schema explícito

tests/conftest.py - linhas 1 a 11

```
import os
import sys
from datetime import datetime

import pytest
from pyspark.sql import SparkSession

from relatorio_pedidos.io_utils.schemas import PagamentosSchema, PedidosSchema

# Garante que os workers Python do Spark usem o mesmo interpretador dos testes.
os.environ.setdefault("PYSPARK_PYTHON", sys.executable)
```

tests/conftest.py - linhas 14 a 32

```python
@pytest.fixture
def spark():
    """SparkSession local compartilhada; recriada se algum teste (ex.: Application) a encerrar."""
    sessao = (
        SparkSession.builder.appName("testes-relatorio-pedidos")
        .master("local[1]")
        .config("spark.sql.shuffle.partitions", "1")
        .config("spark.ui.enabled", "false")
        .config("spark.ui.showConsoleProgress", "false")
        .getOrCreate()
    )
    sessao.sparkContext.setLogLevel("ERROR")
    return sessao


def pytest_sessionfinish(session, exitstatus):
    ativa = SparkSession.getActiveSession()
    if ativa is not None:
        ativa.stop()
```

tests/conftest.py - linhas 35 a 51

```python
@pytest.fixture
def make_pedidos(spark):
    """Cria DataFrame de pedidos com o schema explícito do projeto.

    Cada linha: (id_pedido, valor_unitario, quantidade, data_criacao, uf).
    """

    def _make(linhas):
        dados = [(i, "PRODUTO", float(v), int(q), d, uf, 1) for i, v, q, d, uf in linhas]
        return spark.createDataFrame(dados, schema=PedidosSchema.get())

    return _make


@pytest.fixture
def make_pagamentos(spark):
    """Cria DataFrame de pagamentos com o schema explícito do projeto.
```

tests/conftest.py - linhas 53 a 63

```
    Cada linha: (id_pedido, forma_pagamento, status, fraude).
    """

    def _make(linhas):
        dados = [
            (i, forma, 100.0, status, datetime(2025, 1, 1), (fraude, 0.5))
            for i, forma, status, fraude in linhas
        ]
        return spark.createDataFrame(dados, schema=PagamentosSchema.get())

    return _make
```

Testes unitários da lógica de negócio

tests/test_relatorio_pedidos.py - linhas 1 a 12

```
import logging
from datetime import datetime

import pytest
from pyspark.sql.types import DoubleType, StringType, StructField, StructType, TimestampType

from relatorio_pedidos.business.relatorio_pedidos import RelatorioPedidos, RelatorioPedidosError


@pytest.fixture
def relatorio():
    return RelatorioPedidos(ano=2025)
```

tests/test_relatorio_pedidos.py - linhas 15 a 29

```python
def test_filtra_apenas_pagamentos_recusados_e_legitimos(relatorio, make_pagamentos):
    pagamentos = make_pagamentos(
        [
            ("recusado-legitimo", "PIX", False, False),
            ("recusado-fraude", "PIX", False, True),
            ("aprovado-legitimo", "PIX", True, False),
            ("aprovado-fraude", "PIX", True, True),
            ("status-nulo", "PIX", None, False),
            ("fraude-nula", "PIX", False, None),
        ]
    )

    ids = [r.id_pedido for r in relatorio.filtrar_pagamentos_recusados_legitimos(pagamentos).collect()]

    assert ids == ["recusado-legitimo"]
```

tests/test_relatorio_pedidos.py - linhas 32 a 44

```python
def test_filtra_apenas_pedidos_de_2025(relatorio, make_pedidos):
    pedidos = make_pedidos(
        [
            ("fim-2024", 10, 1, datetime(2024, 12, 31, 23, 59, 59), "SP"),
            ("inicio-2025", 10, 1, datetime(2025, 1, 1, 0, 0, 0), "SP"),
            ("fim-2025", 10, 1, datetime(2025, 12, 31, 23, 59, 59), "SP"),
            ("inicio-2026", 10, 1, datetime(2026, 1, 1, 0, 0, 0), "SP"),
        ]
    )

    ids = sorted(r.id_pedido for r in relatorio.filtrar_ano(pedidos).collect())

    assert ids == ["fim-2025", "inicio-2025"]
```

tests/test_relatorio_pedidos.py - linhas 47 a 65

```python
def test_ano_do_filtro_vem_da_injecao(make_pedidos):
    pedidos = make_pedidos(
        [
            ("a", 10, 1, datetime(2024, 5, 1), "SP"),
            ("b", 10, 1, datetime(2025, 5, 1), "SP"),
        ]
    )

    ids = [r.id_pedido for r in RelatorioPedidos(ano=2024).filtrar_ano(pedidos).collect()]

    assert ids == ["a"]


def test_calcula_valor_total_como_valor_unitario_vezes_quantidade(relatorio, make_pedidos):
    pedidos = make_pedidos([("p1", 150.5, 3, datetime(2025, 3, 1), "RJ")])

    linha = relatorio.calcular_valor_total(pedidos).collect()[0]

    assert linha.valor_total == pytest.approx(451.5)
```

tests/test_relatorio_pedidos.py - linhas 68 a 84

```python
def test_join_descarta_pedidos_sem_pagamento_filtrado(relatorio, make_pedidos, make_pagamentos):
    pedidos = make_pedidos(
        [
            ("p1", 10, 1, datetime(2025, 3, 1), "SP"),
            ("p2", 10, 1, datetime(2025, 3, 2), "SP"),
        ]
    )
    pagamentos = make_pagamentos([("p1", "PIX", False, False)])

    ids = [r.id_pedido for r in relatorio.juntar(pedidos, pagamentos).collect()]

    assert ids == ["p1"]


def test_colunas_finais_do_relatorio(relatorio, make_pedidos, make_pagamentos):
    pedidos = relatorio.calcular_valor_total(make_pedidos([("p1", 10, 2, datetime(2025, 3, 1), "SP")]))
    pagamentos = make_pagamentos([("p1", "BOLETO", False, False)])
```

tests/test_relatorio_pedidos.py - linhas 86 a 105

```
    df = relatorio.selecionar_colunas(relatorio.juntar(pedidos, pagamentos))

    assert df.columns == ["id_pedido", "uf", "forma_pagamento", "valor_total", "data_pedido"]
    assert df.columns == RelatorioPedidos.COLUNAS_RELATORIO


def test_ordena_por_uf_forma_pagamento_e_data(relatorio, spark):
    schema = StructType(
        [
            StructField("id_pedido", StringType()),
            StructField("uf", StringType()),
            StructField("forma_pagamento", StringType()),
            StructField("valor_total", DoubleType()),
            StructField("data_pedido", TimestampType()),
        ]
    )
    df = spark.createDataFrame(
        [
            ("d", "SP", "PIX", 1.0, datetime(2025, 1, 1)),
            ("c", "SP", "BOLETO", 1.0, datetime(2025, 2, 1)),
```

tests/test_relatorio_pedidos.py - linhas 106 a 114

```
            ("b", "AC", "PIX", 1.0, datetime(2025, 3, 1)),
            ("a", "AC", "PIX", 1.0, datetime(2025, 1, 15)),
        ],
        schema=schema,
    )

    ids = [r.id_pedido for r in relatorio.ordenar(df).collect()]

    assert ids == ["a", "b", "c", "d"]
```

tests/test_relatorio_pedidos.py - linhas 117 a 135

```python
def test_gerar_relatorio_de_ponta_a_ponta(relatorio, make_pedidos, make_pagamentos):
    pedidos = make_pedidos(
        [
            ("ok-sp", 100, 2, datetime(2025, 6, 1, 10), "SP"),
            ("ok-ac", 50, 3, datetime(2025, 7, 1, 10), "AC"),
            ("aprovado", 100, 1, datetime(2025, 6, 1), "SP"),
            ("fraude", 100, 1, datetime(2025, 6, 1), "SP"),
            ("ano-2024", 100, 1, datetime(2024, 6, 1), "SP"),
        ]
    )
    pagamentos = make_pagamentos(
        [
            ("ok-sp", "PIX", False, False),
            ("ok-ac", "BOLETO", False, False),
            ("aprovado", "PIX", True, False),
            ("fraude", "PIX", False, True),
            ("ano-2024", "PIX", False, False),
        ]
    )
```

tests/test_relatorio_pedidos.py - linhas 137 a 154

```python
    linhas = relatorio.gerar_relatorio(pedidos, pagamentos).collect()

    assert [(r.id_pedido, r.uf, r.forma_pagamento, r.valor_total) for r in linhas] == [
        ("ok-ac", "AC", "BOLETO", 150.0),
        ("ok-sp", "SP", "PIX", 200.0),
    ]
    assert linhas[0].data_pedido == datetime(2025, 7, 1, 10)


def test_erro_em_etapa_e_logado_e_relancado_de_forma_controlada(relatorio, make_pagamentos, spark, caplog):
    pedidos_sem_data = spark.createDataFrame(
        [("p1", "SP")], StructType([StructField("id_pedido", StringType()), StructField("uf", StringType())])
    )
    pagamentos = make_pagamentos([("p1", "PIX", False, False)])

    with caplog.at_level(logging.ERROR):
        with pytest.raises(RelatorioPedidosError, match="Filtro do ano"):
            relatorio.gerar_relatorio(pedidos_sem_data, pagamentos)
```

tests/test_relatorio_pedidos.py - linhas 156 a 172

```
156     assert any("Falha na etapa 'Filtro do ano'" in m for m in caplog.messages)
157
158
159 def test_contagens_podem_ser_desligadas(make_pedidos, make_pagamentos, caplog):
160     pedidos = make_pedidos([("p1", 10, 1, datetime(2025, 3, 1), "SP")])
161     pagamentos = make_pagamentos([("p1", "PIX", False, False)])
162
163     with caplog.at_level(logging.INFO):
164         RelatorioPedidos(ano=2025, log_contagens=False).gerar_relatorio(pedidos, pagamentos)
165
166     assert not any("registros" in m for m in caplog.messages)
167     assert any(m == "Etapa 'Ordenação' concluída" for m in caplog.messages)
168
169
170 def test_registra_contagem_de_cada_etapa(relatorio, make_pedidos, make_pagamentos, caplog):
171     pedidos = make_pedidos([("p1", 10, 1, datetime(2025, 3, 1), "SP")])
172     pagamentos = make_pagamentos([("p1", "PIX", False, False)])
```

tests/test_relatorio_pedidos.py - linhas 174 a 179

```
174     with caplog.at_level(logging.INFO):
175         relatorio.gerar_relatorio(pedidos, pagamentos)
176
177     etapas = [m for m in caplog.messages if m.startswith("Etapa '")]
178     assert len(etapas) == 6
179     assert all("1 registros" in m for m in etapas)
```

Testes da orquestração com dependências injetadas (mocks)

tests/test_pipeline.py - linhas 1 a 16

```python
from datetime import datetime
from unittest.mock import MagicMock

import pytest

from relatorio_pedidos.business.relatorio_pedidos import RelatorioPedidos, RelatorioPedidosError
from relatorio_pedidos.pipeline.pipeline import Pipeline


def test_pipeline_orquestra_leitura_transformacao_e_escrita(make_pedidos, make_pagamentos):
    reader, writer = MagicMock(), MagicMock()
    reader.read_pedidos.return_value = make_pedidos([("p1", 10, 1, datetime(2025, 3, 1), "SP")])
    reader.read_pagamentos.return_value = make_pagamentos([("p1", "PIX", False, False)])
    writer.write.return_value = "saida"

    caminho = Pipeline(reader, RelatorioPedidos(ano=2025), writer).run()
```

tests/test_pipeline.py - linhas 18 a 32

```python
    assert caminho == "saida"
    reader.read_pedidos.assert_called_once()
    reader.read_pagamentos.assert_called_once()
    df_gravado = writer.write.call_args.args[0]
    assert [r.id_pedido for r in df_gravado.collect()] == ["p1"]


def test_pipeline_nao_grava_quando_a_regra_de_negocio_falha():
    reader, writer, relatorio = MagicMock(), MagicMock(), MagicMock()
    relatorio.gerar_relatorio.side_effect = RelatorioPedidosError("falhou")

    with pytest.raises(RelatorioPedidosError):
        Pipeline(reader, relatorio, writer).run()

    writer.write.assert_not_called()
```

Execução do pipeline (logs)

python main.py - linhas 1 a 10

```
2026-10-13 22:12:58,490 - INFO - Pipeline iniciado
2026-10-13 22:12:59,170 - INFO - Iniciando a geração do relatório (ano 2025)
2026-10-13 22:13:01,118 - INFO - Etapa 'Filtro do ano' concluída: 31680 registros
2026-10-13 22:13:01,317 - INFO - Etapa 'Cálculo do valor total' concluída: 31680 registros
2026-10-13 22:13:01,794 - INFO - Etapa 'Filtro de pagamentos recusados e legítimos' concluída: 2747 registros
2026-10-13 22:13:02,817 - INFO - Etapa 'Join pedidos x pagamentos' concluída: 1473 registros
2026-10-13 22:13:03,190 - INFO - Etapa 'Seleção de colunas' concluída: 1473 registros
2026-10-13 22:13:03,522 - INFO - Etapa 'Ordenação' concluída: 1473 registros
2026-10-13 22:13:03,522 - INFO - Relatório gerado com sucesso
2026-10-13 22:13:07,716 - INFO - Pipeline concluído. Parquet gravado em: data/output/relatorio_pedidos
```

Arquivos do parquet gerado

listagem de data/output/relatorio_pedidos - linhas 1 a 4

```
       8 bytes  ._SUCCESS.crc
     572 bytes  .part-00000-50ef623b-a1f7-4366-a6dd-d4d1737aeee9-c000.snappy.parquet.crc
       0 bytes  _SUCCESS
   72117 bytes  part-00000-50ef623b-a1f7-4366-a6dd-d4d1737aeee9-c000.snappy.parquet
```

Validações do parquet

python scripts/validar_saida.py - linhas 1 a 8

```
[OK] colunas == ['id_pedido', 'uf', 'forma_pagamento', 'valor_total', 'data_pedido']
[OK] contagem == 1473 (cálculo independente)
[OK] id_pedido sem duplicidade
[OK] todos os pedidos de 2025
[OK] todos com status=false e fraude=false
[OK] valor_total == valor_unitario * quantidade
[OK] ordenado por uf, forma_pagamento, data_pedido
Total de linhas: 1473
```

Amostra do parquet (schema e primeiras linhas)

python scripts/validar_saida.py - linhas 1 a 19

```
root
 |-- id_pedido: string (nullable = true)
 |-- uf: string (nullable = true)
 |-- forma_pagamento: string (nullable = true)
 |-- valor_total: double (nullable = true)
 |-- data_pedido: timestamp (nullable = true)
+------------------------------------+---+---------------+-----------+-------------------+
|id_pedido                           |uf |forma_pagamento|valor_total|data_pedido        |
+------------------------------------+---+---------------+-----------+-------------------+
|acbf9b42-eaca-4cd9-914a-109de59aa943|AL |BOLETO         |2500.0     |2025-02-02 17:02:14|
|df280f1a-b8f4-4a29-be64-66fb7fab2a25|AL |BOLETO         |1100.0     |2025-06-12 12:29:22|
|394c5640-fae2-413f-bdfb-52f316fa6782|AL |CARTAO_CREDITO |5000.0     |2025-01-03 18:49:13|
|4440113d-717d-4887-8889-574853e47e20|AL |CARTAO_CREDITO |1100.0     |2025-03-06 06:33:11|
|cdbf1791-ad2f-4357-af93-1af7e9545214|AL |CARTAO_CREDITO |600.0      |2025-03-15 13:24:44|
|a66abc7f-d362-4942-8be9-e6f7b696b14e|AL |CARTAO_CREDITO |300.0      |2025-03-27 20:28:37|
|9b459f36-d5b9-4b1a-91d9-0be858e369dc|AL |CARTAO_CREDITO |30.0       |2025-04-18 16:21:57|
|f70efb0f-6457-4356-aa20-a72c7fb0b45f|AL |CARTAO_CREDITO |1500.0     |2025-04-27 11:16:35|
+------------------------------------+---+---------------+-----------+-------------------+
only showing top 8 rows
```

Execução dos testes (pytest)

pytest -v - linhas 1 a 12

```
============================= test session starts ==============================
collecting ... collected 21 items
tests/test_integracao.py::test_schemas_sao_explicitos_e_incluem_o_objeto_aninhado PASSED [  4%]
tests/test_integracao.py::test_escrita_em_parquet_preserva_os_dados PASSED [  9%]
tests/test_integracao.py::test_aplicacao_executa_o_pipeline_completo PASSED [ 14%]
tests/test_integracao.py::test_cli_encerra_com_codigo_1_quando_a_entrada_nao_existe PASSED [ 19%]
tests/test_integracao.py::test_aplicacao_retorna_erro_quando_a_entrada_nao_existe PASSED [ 23%]
tests/test_pipeline.py::test_pipeline_orquestra_leitura_transformacao_e_escrita PASSED [ 28%]
tests/test_pipeline.py::test_pipeline_nao_grava_quando_a_regra_de_negocio_falha PASSED [ 33%]
tests/test_relatorio_pedidos.py::test_filtra_apenas_pagamentos_recusados_e_legitimos PASSED [ 38%]
tests/test_relatorio_pedidos.py::test_filtra_apenas_pedidos_de_2025 PASSED [ 42%]
tests/test_relatorio_pedidos.py::test_ano_do_filtro_vem_da_injecao PASSED [ 47%]
```

pytest -v - linhas 13 a 24

```
tests/test_relatorio_pedidos.py::test_calcula_valor_total_como_valor_unitario_vezes_quantidade PASSED [ 52%]
tests/test_relatorio_pedidos.py::test_join_descarta_pedidos_sem_pagamento_filtrado PASSED [ 57%]
tests/test_relatorio_pedidos.py::test_colunas_finais_do_relatorio PASSED [ 61%]
tests/test_relatorio_pedidos.py::test_ordena_por_uf_forma_pagamento_e_data PASSED [ 66%]
tests/test_relatorio_pedidos.py::test_gerar_relatorio_de_ponta_a_ponta PASSED [ 71%]
tests/test_relatorio_pedidos.py::test_erro_em_etapa_e_logado_e_relancado_de_forma_controlada PASSED [ 76%]
tests/test_relatorio_pedidos.py::test_contagens_podem_ser_desligadas PASSED [ 80%]
tests/test_relatorio_pedidos.py::test_registra_contagem_de_cada_etapa PASSED [ 85%]
tests/test_settings.py::test_padroes_quando_nao_ha_yaml PASSED           [ 90%]
tests/test_settings.py::test_yaml_sobrescreve_padroes PASSED             [ 95%]
tests/test_settings.py::test_variaveis_de_ambiente_tem_precedencia_sobre_o_yaml PASSED [100%]
============================== 21 passed in 59.65s ==============================
```